Taller 7: Pipeline para detección y corrección de errores médicos (MEDEC / MEDIQA-CORR 2024)

Cristian Organista, Fabián Ramírez, Cristhian Bolaños

2 de noviembre de 2026

1 Objetivo

1. Leer los artículos de referencia:
   - *MEDEC: A Benchmark for Medical Error Detection and Correction in Clinical Notes* (Ben Abacha et al., 2025).
   - *WangLab at MEDIQA-CORR 2024: Optimized LLM-based Programs for Medical Error Detection and Correction* (Toma et al., 2024).
2. Revisar el dataset de entrenamiento **MEDIQA-CORR 2024 MS**.
3. Plantear un pipeline que resuelva las tareas con modelos de **Hugging Face**, indicando el modelo a usar y las funciones a programar en cada etapa.

2 Archivos entregados

Archivo	Descripción
analisis_dataset.ipynb	Análisis exploratorio del dataset, con gráficas y conclusiones.
data/MEDIQA-CORR-2024-MS-TrainingData.csv	Conjunto de entrenamiento MS (2.189 textos clínicos).
data/*.pdf	Artículos de referencia.
requirements.txt	Dependencias para ejecutar el notebook.
pipeline.html	(Opcional) Versión interactiva del diagrama del pipeline: se abre en cualquier navegador y al hacer clic en cada caja muestra su detalle.

Para ejecutar el análisis:

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
jupyter notebook analisis_dataset.ipynb
```

3 La tarea

Cada texto clínico es **correcto o tiene exactamente un error** médico (diagnóstico, manejo, tratamiento, farmacoterapia u organismo causal). Hay tres subtareas:

Subtarea	Entrada	Salida	Métrica
A. Error flag	Texto clínico	`0` / `1`	Accuracy
B. Error sentence	Texto segmentado en oraciones	ID de la oración con error, `-1` si no hay	Accuracy
C. Corrección	Texto + oración con error	Oración corregida, `NA` si no hay error	ROUGE-1, BERTScore

3.1 Métricas de evaluación

Se usan tres de las métricas oficiales del shared task MEDIQA-CORR 2024, descritas en la sección 5.2 de MEDEC y en la sección 3 del artículo de WangLab (scripts de evaluación). En las métricas de corrección se compara la oración generada con la de referencia.

Métrica	Subtarea	Qué mide	Ejemplo
Accuracy	A y B	Porcentaje de textos donde la predicción coincide con la etiqueta (el flag en A, el ID de la oración en B).	Si de 100 textos se acierta el flag en 70, la accuracy de A es 0,70.
ROUGE-1	C	Traslape de palabras individuales (unigramas) entre la corrección generada y la de referencia, como F1 de precisión y recall.	Referencia: *"The causal pathogen is Streptococcus pneumoniae."* Generada: *"… Streptococcus pyogenes."* Coinciden 5 de 6 palabras: puntaje alto aunque la bacteria esté mal.
BERTScore	C	Similitud de significado: compara los embeddings de cada token con un modelo BERT (`microsoft/deberta-xlarge-mnli`), dando puntaje parcial a palabras parecidas.	*"… X-linked agammaglobulinemia"* frente a *"… Bruton agammaglobulinemia"*: puntúa mejor que ROUGE porque los embeddings son cercanos.

4 Hallazgos del dataset que guían el diseño

El detalle completo está en `analisis_dataset.ipynb`.

- **55,7 %** de los textos tienen error: clases casi balanceadas.
- Textos cortos (mediana 167 tokens, máximo 414 con el tokenizador de BiomedBERT): **caben completos en un encoder de 512 tokens** junto con la oración candidata.
- El error está en la **última oración en el 62,5 %** de los casos: hay un sesgo de posición fuerte.
- Solo hay **1.240 casos clínicos distintos**: 934 aparecen dos veces (versión correcta y versión con error). El split de validación debe ser **agrupado por caso**.
- La corrección es casi siempre el **reemplazo de una entidad** (82,5 % cambia un solo bloque; mediana de 2 palabras).
- Los textos MS se construyeron a partir de preguntas de opción múltiple de **MedQA**. Buscar la pregunta original equivale a consultar la respuesta, así que se deja fuera del pipeline principal y se evalúa como experimento aparte.

5 Pipeline propuesto

La idea combina lo mejor de los dos artículos con modelos abiertos de Hugging Face que se pueden correr en Colab:

- Del artículo de **WangLab**: descomponer el problema en *detectar, localizar y corregir* y opti-

mizar los prompts del LLM con **DSPy**.

- De **MEDEC**: los LLM solos tienen baja precisión (detectan errores donde no los hay); por eso, además del LLM, se entrena un **clasificador biomédico fine-tuneado** con umbral calibrado.

Para la detección (subtareas A y B) se usan **dos detectores en paralelo** y se combinan con un promedio ponderado:

1. **Detector fine-tuneado:** BiomedBERT ajustado con nuestros datos. Da una probabilidad de error por oración.
2. **Detector DSPy:** Qwen2.5-7B con un programa DSPy compilado, como en WangLab pero con un modelo abierto. Devuelve la oración sospechosa y una confianza.

Así se comparan las dos estrategias (cambiar los pesos del modelo frente a optimizar el prompt) y, además, se aprovecha lo mejor de ambas.

Como **referencia externa** se evalúa además un LLM grande vía API, **Claude Opus 5.5**, con el mismo tipo de prompt que usó MEDEC y sin entrenamiento ni optimización. No entra en la combinación: sirve para saber qué tan lejos queda nuestro pipeline de un modelo comercial grande y para comparar directamente con la tabla del artículo.

El pipeline principal **no usa MedQA**: los modelos solo ven el texto clínico. Usar MedQA (como hizo WangLab) se evalúa en un **experimento aparte** para medir cuánto sube el resultado al tener esa pista. En la Figura 1, **[HF]** marca los pasos que usan modelos, datasets o librerías de Hugging Face.

5.1 Resumen paso a paso

Paso	Qué hace	Con qué
1. Preparar los datos	Lee los textos, reconstruye las oraciones y separa entrenamiento y validación sin repetir un mismo caso clínico en los dos lados.	pandas
2. Armar los ejemplos	Convierte cada texto en pares *(oración, texto completo)*, que es lo que recibe el modelo entrenado.	Tokenizador de BiomedBERT **[HF]**
3a. Modelo entrenado	Aprende con nuestros datos a decir qué tan probable es que cada oración sea el error.	BiomedBERT con fine-tuning **[HF]**
3b. LLM con prompt optimizado	Un LLM lee el texto y señala la oración sospechosa. DSPy elige los ejemplos que mejor funcionan en su prompt.	Qwen2.5-7B + DSPy **[HF]**
3c. Combinar las dos respuestas	Promedia las dos opiniones dando más peso al modelo entrenado. Si ninguna oración es lo bastante sospechosa, el texto se considera correcto.	–
4. Corregir la oración	El LLM reescribe la oración con error usando su conocimiento médico y ejemplos parecidos del entrenamiento.	Qwen2.5-7B **[HF]**
5. Revisar la corrección	Si la corrección quedó igual o cambió demasiado, se marca como dudosa para analizarla.	ROUGE **[HF]**
6. Evaluar y comparar	Mide los aciertos en detección (A y B) y la calidad de la corrección (C) de cada sistema.	`evaluate` **[HF]**
Referencia externa	Un LLM comercial grande resuelve las tres subtareas sin entrenamiento, solo para comparar.	Claude Opus 5.5 (API)
Experimento: pista de MedQA	Repite los pasos 3 a 5 dándoles además la pregunta de examen más parecida y su respuesta, para medir cuánto ayuda esa "hoja de respuestas".	MedQA + PubMedBERT embeddings **[HF]**

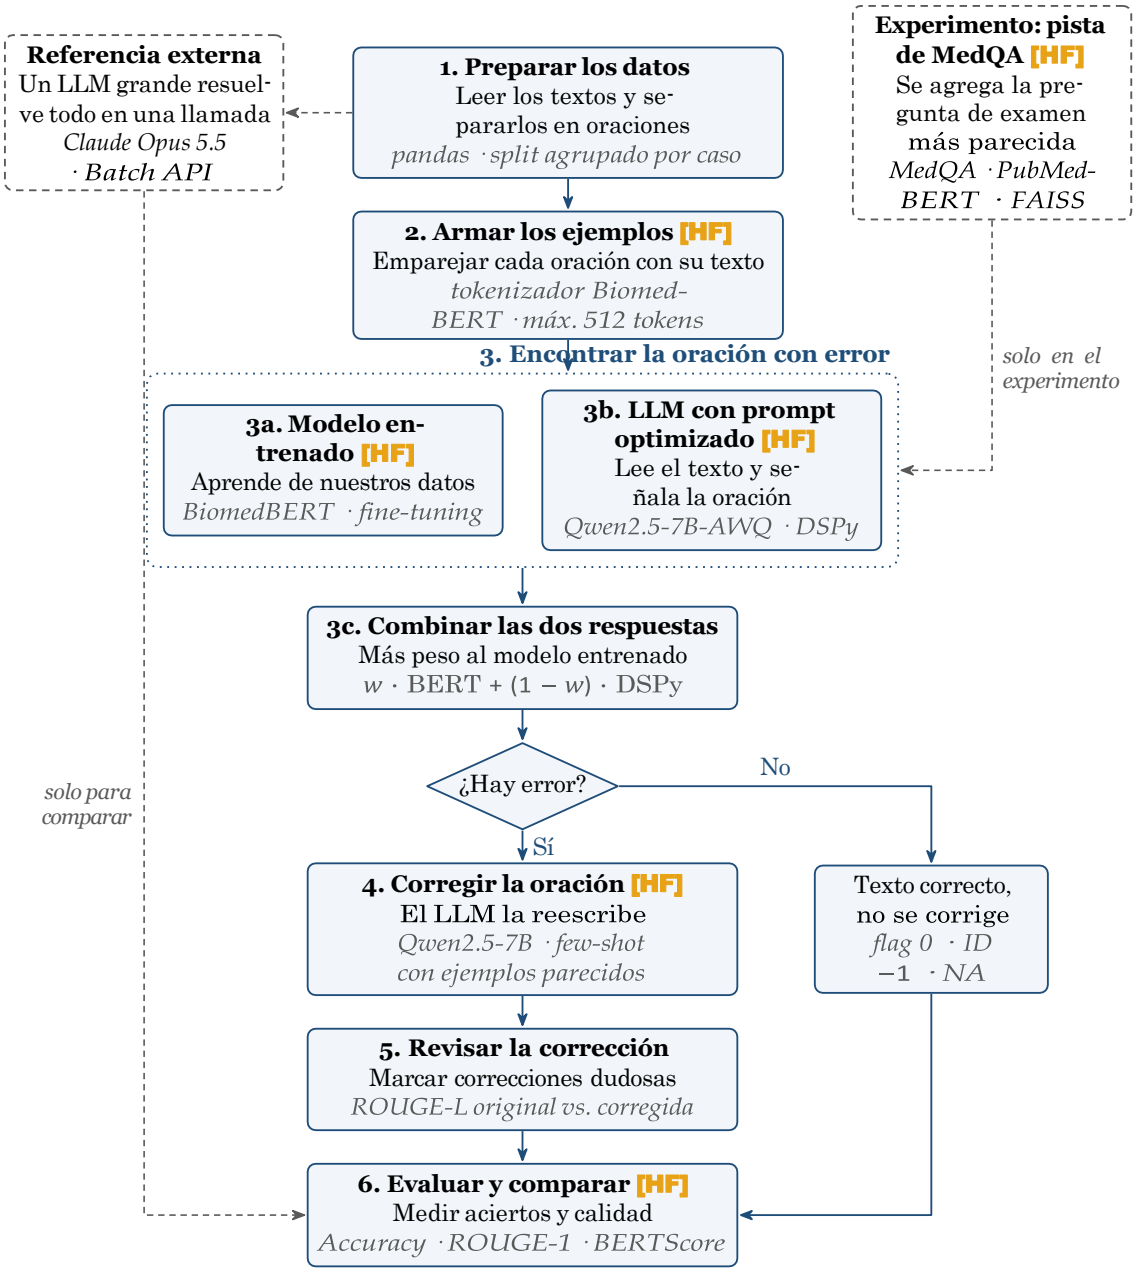


Figura 1: Pipeline propuesto. Las cajas punteadas no forman parte del pipeline principal. **[HF]** = usa recursos de Hugging Face.

5.2 Modelos y recursos

Rol	Modelo / dataset / librería	¿De Hugging Face?	Por qué
Detector fine-tuneado (A y B)	microsoft/BiomedNLP-BiomedBERT-base-uncased-abstract-fulltext	Sí: modelo del Hub, se entrena con transformers	Encoder preentrenado en PubMed: entiende vocabulario médico y se puede fine-tunear en una T4.
LLM (detector DSPy y corrector)	Qwen/Qwen2.5-7B-Instruct-AWQ	Sí: modelo del Hub, cuantizado a 4 bits (AWQ)	LLM instruccional abierto que cabe en una T4. Se sirve **una sola vez** con vLLM y lo usan el detector DSPy y el corrector.
Embeddings	NeuML/pubmedbert-base-embeddings	Sí: modelo del Hub, con sentence-transformers	Sentence-transformer biomédico. En el pipeline elige ejemplos parecidos del train para el corrector; en el experimento, busca preguntas de MedQA.
Optimización de prompts	DSPy	No: librería de Stanford	Compila el detector LLM (elige ejemplos few-shot según una métrica), como en WangLab.
Servidor del LLM	vLLM	No, pero descarga el modelo desde el Hub	Expone Qwen con una API compatible con OpenAI, que es lo que DSPy sabe llamar; procesa muchas peticiones en paralelo.
Referencia: LLM grande	claude-opus-5-5 con el SDK oficial anthropic	No: API de pago de Anthropic	Modelo comercial grande, comparable con los LLMs que evaluó MEDEC (incluido Claude 3.5 Sonnet). Se usa con *structured outputs* y Batch API.
Métricas	evaluate (ROUGE), bert-score	evaluate sí; BERTScore usa microsoft/deberta-xlarge-mnli del Hub	ROUGE-1 y BERTScore, comparables con los artículos.
Experimento: base de conocimiento	GBaker/MedQA-USMLE-4-options	Sí: dataset del Hub, con datasets	Preguntas de examen con opciones y respuesta correcta, origen de los textos MS. Solo se usa en el experimento.